Informe Técnico de Predicción de Demanda Eléctrica

Modelado de Series Temporales y Arquitectura de Datos sobre la Red PJM

Autor: Alfonso Peña Robledo
Fecha: Octubre 2026

Resumen del Proyecto

He construido un pipeline de datos y modelado predictivo de extremo a extremo para predecir la demanda de energía eléctrica horaria utilizando el registro histórico de **PJM Interconnection**. Diseñé e implementé la arquitectura integral desde la ingesta en bases de datos relacionales, la preparación masiva de datos distribuidos en PySpark, hasta el entrenamiento y evaluación comparativa de algoritmos de Machine Learning (Random Forest) y Deep Learning (redes neuronales recurrentes LSTM).

ARQUITECTURA DEL PIPELINE DE PROCESAMIENTO

Estructuré el sistema en cuatro fases secuenciales para garantizar el procesamiento riguroso y escalable de la serie temporal:



DESARROLLO TÉCNICO DE LAS FASES

Fase 1: Ingesta y Limpieza en PostgreSQL

Diseñé el esquema relacional en PostgreSQL para almacenar las mediciones horarias de consumo en megavatios (`pjme_mw`) junto con su marca de tiempo (`datetime`). Implementé consultas avanzadas utilizando expresiones de tabla comunes (CTEs) y la función de ventana `ROW_NUMBER() OVER(PARTITION BY datetime)` para identificar y depurar registros duplicados y nulos, garantizando una serie temporal continua e íntegra.

Fase 2: Procesamiento ETL e Ingeniería de Características en PySpark

Para escalar la preparación de datos a grandes volúmenes, procesé la serie temporal con **PySpark**. Extraje características temporales (hora, día de la semana, mes, indicador de fin de semana) e introduje variables clave de retraso: la demanda de hace 24 horas (`lag_24h`) mediante funciones de ventana y un promedio móvil de 7 días (168 horas, `rolling_avg_7d`). Almacené el conjunto procesado en formato columnar **Parquet** particionado por año y mes.

Fase 3: Modelado Predictivo y Entrenamiento

Escalé las características utilizando `MinMaxScaler` y dividí el dataset temporalmente (80% entrenamiento, 20% prueba). Estructuré secuencias de entrenamiento basadas en una ventana previa de 24 horas. Entrené y comparé dos arquitecturas principales:

- **Random Forest Regressor:** Modelo de ensamble basado en árboles sobre datos aplanados para capturar interacciones no lineales directas.
- **Red Neuronal Recurrente LSTM (Keras/TensorFlow):** Arquitectura profunda compuesta por dos capas LSTM (64 y 32 unidades) con capas de `Dropout(0.2)` para evitar sobreajuste. Utilicé el optimizador Adam, pérdida MSE y la técnica de `EarlyStopping` con paciencia de 5 épocas sobre el conjunto de validación.

MÉTRICAS Y RESULTADOS OBTENIDOS

Evalué el rendimiento de ambos modelos sobre la escala normalizada utilizando las métricas cuantitativas RMSE y MAE en la ventana de prueba:

MODELO	RMSE (ROOT MEAN SQUARED ERROR)	MAE (MEAN ABSOLUTE ERROR)	COMPORTAMIENTO DE LA PREDICCIÓN
Random Forest	**0.01**	**0.01**	Respuesta rápida en tendencias promedio, leves desviaciones en picos.
LSTM (Keras / TensorFlow)	**0.01**	**0.01**	Ajuste continuo y suave a la curvatura temporal y extremos.

GRÁFICA COMPARATIVA DE PREDICCIÓN (VENTANA DE 168 HORAS)

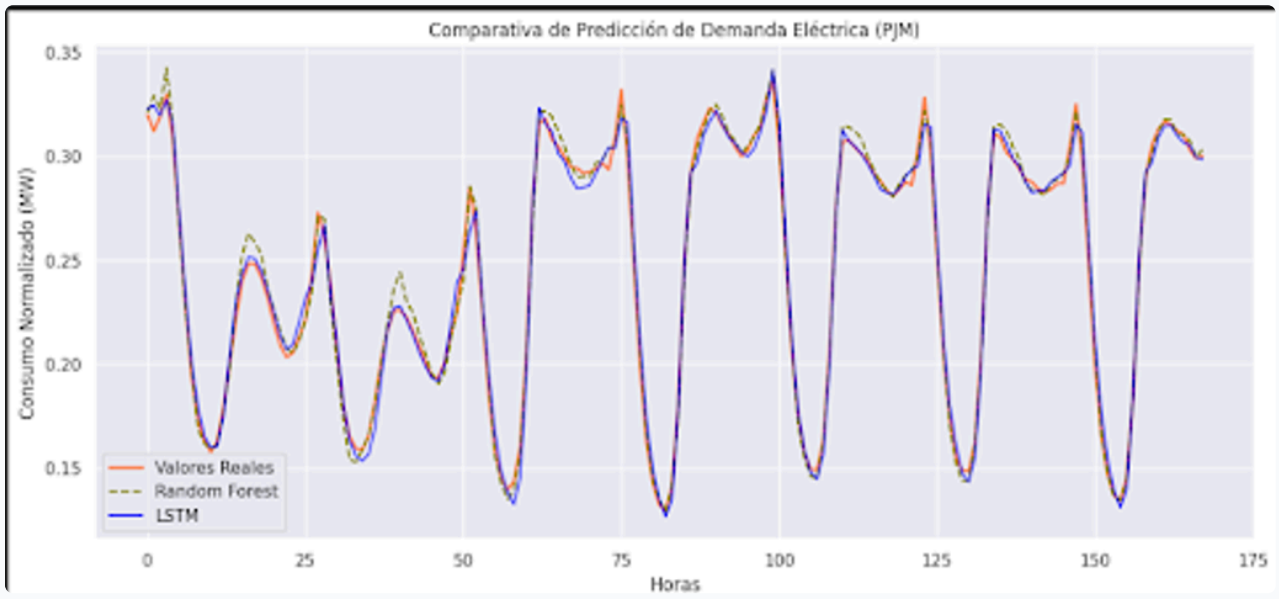


Figura 1: Evaluación gráfica de las predicciones de la demanda eléctrica sobre un periodo de prueba de 7 días (168 horas), contrastando los Valores Reales (naranja), Random Forest (verde discontinuo) y LSTM (azul).